

个人简历

求职意向：大模型算法工程师

姓名：马旭旭

籍贯：陕西省延安市

出生年月：2002年11月

手机号码：18700152881

邮箱：18700152881@163.com

薪资：面议



个人技能 PERSONAL SKILLS

- 熟练RAG技术，熟悉混合检索及Rerank重排序，能够在不同的应用场景中合理使用信息检索和生成技术，提升模型性能和精度。
- 掌握向量数据库的构建与应用，熟悉文档切分策略、Embedding模型的选型与应用，能够进行重排序优化，提升数据存储和查询效率，支持大规模数据处理。
- 熟练运用LangChain框架进行大模型应用开发，掌握Chains、Agents、Memory等核心组件的设计与编排，能够灵活实现复杂的应用逻辑，确保系统的高效性和可扩展性。
- 熟悉Coze、Dify及RAGFlow开发工具，具备企业级RAG知识库搭建经验，熟悉混合检索与重排序机制，能够进行知识库管理及LLM应用部署，可根据业务需求调整系统功能。
- 熟悉Transformer架构及主流预训练模型，具备大模型微调、Prompt Engineering和API服务化部署等项目经验。
- 熟练Python编程，能够编写高效的Python代码，使用API进行AI模型与业务系统的交互，确保数据流畅传递和任务自动化。
- 熟练FastAPI与Pydantic，能够快速搭建高性能的REST API服务，自动实现数据校验，生成Swagger文档，确保接口规范与数据的完整性。
- 熟练MySQL数据库操作，能够高效编写SQL语句进行数据查询、更新与优化。同时对Redis和MongoDB有一定的理解，能够在适当场景中应用这些技术。



实习经历 INTERNSHIP EXPERIENCE

时间：2024.12-2026.01 名称：广州荔支网络技术有限公司 职位：AI算法实习生

主要职责：

- 设计和开发智能检索系统，结合大语言模型与向量数据库进行文本语义理解和精准匹配，提升检索精度和效率。
- 构建基于大模型的智能对话系统，使用LangChain等框架设计多轮对话流程，优化对话策略、提示语、记忆管理和工具调用，提高自动化能力和用户体验。
- 集成大语言模型（如Qwen-Plus、BERT）到实际应用中，解决智能化需求，提升系统的理解和生成能力。

工作成果：

- 在项目“求职导航”中，优化检索引擎，结合向量数据库与传统算法，在万级数据下实现毫秒级响应，检索准确率提升35%，召回率达92%以上，满足高并发场景需求。

2. 优化智能问答系统，提升对话解决率25%、用户满意度30%，减少对话轮次40%、人工干预需求50%，大幅提升自动化和用户体验。

项目经历 PROJECT EXPERIENCE

时间：2025.09-2025.12 项目名称：“求职导航”项目 职位：AI算法实习生

- **项目介绍:** “求职导航”是一个创新型的智能求职平台项目。它采用强大的技术栈，以Python为编程基础，融合Bert、Milvus实现精准的语义理解和向量检索，让求职者与梦想岗位越来越近；借助BM25提升传统检索效率。同时，利用LangChain构建智能交互流程，结合qwen-plus等模型增强对话能力。通过FastAPI搭建高效稳定的后端接口，Mysql存储结构化数据，Redis缓存热点信息，全方位提升求职体验，为求职市场带来全新变革。

- **技术栈:** Bert + Milvus + BM25 + LangChain + Mysql + Redis + bge-m3 + qwen-plus + FastAPI

- **个人职责:**

1. 智能检索与推荐系统开发：负责开发智能问答匹配算法，使用bge-m3模型进行文本向量化，结合Milvus向量数据库和BM25关键词检索实现混合搜索，提升求职问题与答案匹配的准确性，实现毫秒级响应的海量问答语义检索。

2. LLM智能对话流程架构：基于LangChain框架集成qwen-plus大模型构建智能问答系统,通过Prompt优化、对话记忆管理和工具调用，实现求职问题的智能匹配与多轮咨询，提升用户服务自动化水平。

3. 高并发后端系统建设：负责FastAPI后端开发与性能优化，实现MySQL分库分表和读写分离，设计Redis多级缓存与热点数据预加载,优化高并发场景下的接口响应速度，保障系统稳定性。

- **成果展示:**

1. 混合检索引擎性能突破：构建基于bge-m3向量模型和BM25关键词检索的混合搜索引擎，实现百万级问答库的毫秒级语义检索(平均响应<80ms)，问题匹配准确率较传统方案提升35%，召回率达92%以上。

2. 大模型对话系统落地：基于LangChain框架完成qwen-plus大模型的工程化封装，设计RAG增强检索链与多轮记忆机制，使智能客服覆盖12类高频求职咨询场景，对话解决率达85%，平均对话轮次减少40%，显著降低人工客服压力。

时间：2025.06-2025.08 项目名称：“法智助手”项目 职位：AI算法实习生

- **项目介绍:**基于Dify平台开发的AI法律咨询系统，通过可视化工作流编排与RAG知识库引擎，实现秒级法条检索、类案匹配、胜败诉分析及个性化法律报告生成。旨在零代码搭建专业级法律服务应用，解决传统咨询高门槛、高成本、高延迟等痛点。

- **技术栈:** Dify + LLM + RAG + RAGFlow + OCR + Rerank + text-embedding-v1 + Milvus。

- **个人职责:**

1. 法条检索流：采用“Rewrite-Rerank-RAG”三段式，重写用户口语化问题，召回相关条文并重排，生成带条款号的解读。

2. 类案推荐流：结合案情关键词进行召回，输出相关类案信息，包括胜败诉率、法院层级、赔偿额等内容。

3. AI 律师对话流：设计多轮动态提示，根据用户身份自动切换话术，并嵌入免责声明和证据清单模板，确保合规。

- **项目效果:**

1. 提升法律服务效率：通过秒级法条检索与类案匹配，系统在30天内成功服务了2.2万名用户，显著减少了传统法律咨询中的等待时间，为用户提供了即时、精准的法律建议。

2. 精准个性化法律咨询：基于 RAG 技术和多轮 AI 律师对话流，系统能够根据用户需求自动调整响应，生成个性化法律报告，提高了30%的咨询质量与准确性。

时间: 2025.01-2025.05 项目名称: “动物社交圈”项目 职位: AI算法实习生

- **项目介绍:**这是一个流浪动物收养网站后端 API 服务，采用异步 Python 框架 FastAPI 开发，使用 MySQL 作为数据库存储，通过 SQLAlchemy ORM 进行数据访问。系统提供完整的用户管理、流浪动物的信息发布与浏览、评论、关注博主、收藏以及浏览历史记录功能。

- **技术栈:** FastAPI + MySQL + SQLAlchemy + aiomysql + passlib + bcrypt + Redis + Python asyncio

- **个人职责:**

1. 负责收藏模块：利用 SQLAlchemy 精心设计数据库表结构，通过 FastAPI 开发接口，确保业务逻辑准确高效。通过 MySQL 优化查询，保证数据一致性与准确性。

2. 负责浏览历史模块：设计数据库表记录用户浏览行为，开发高效接口保障系统稳定性。通过 Redis 缓存提升接口响应速度，并定期清理无效数据，优化存储与分析。

- **成果展示:**

1. 系统架构采用异步设计，提升吞吐量 80%，显著提高高并发情况下的处理能力，日 API 调用量突破数百万次。

2. 引入 Redis 缓存后，核心接口响应时间平均缩短 55%，显著提升用户体验与交互流畅度。

3. 使用 SQLAlchemy 简化数据操作，提高开发效率 40%，减少代码量并有效降低后期维护成本。

教育背景 EDUCATIONAL BACKGROUND

2022.06-至今

西安明德理工学院

计算机科学与技术

获奖经历:

2024全国大学生数学建模竞赛 省级二等奖

2024美国大学生数学建模竞赛 H奖 (Honorable Mention)

2025全国大学生数学建模竞赛 省级二等奖

自我评价 SELF-EVALUATION

对技术充满好奇，具备强大的自主学习与问题解决能力，享受攻克技术难题带来的成就感。

对代码质量有高度的责任心，注重细节，具备良好的编码规范意识。

具备坚韧的毅力，在面对挑战时能保持耐心与专注，确保问题被彻底解决。