

基本信息

姓名：郭思宇 出生年月：2004-06
性别：男 籍贯：山西省临汾市
电话：19834864753 邮箱：19834864753@163.com
到岗时间：一周内到岗 求职意向：AI算法工程师



技能特长

- 精通医疗领域RAG系统架构：独立设计并实现高频问答模块，参与混合检索模块部分工作
- 熟悉RAG全流程优化：从Query预处理、意图识别到混合检索、生成模块，实现端到端优化
- 熟练 Python 编程并使用 NumPy, Pandas 等库对数据进行处理，具备良好的编程规范
- 熟练使用 PyCharm, Jupyter, Notebook, Linux 等开发环境
- 熟练使用SQL及数据库进行数据查询与分析
- 掌握深度学习、自然语言处理等算法
- 掌握 Transformer 原理, Attention 机制原理及实现
- 熟练使用 PyTorch、HuggingFace、Fasttext、Ollama、LangChain 等工具进行模型搭建和训练
- 熟悉 NLP、词向量训练、分词、序列标注、关键字提取、文本生成、命名实体识别等问题
- 了解模型量化、蒸馏等技术的应用经验，能够在资源受限的环境下优化模型
- 熟练掌握 LLM Function Calling 技术，能够为大模型集成外部 API（如地图、天气、图片服务），解决模型幻觉与实时数据问题

工作经历

2025-04 ~ 2025-10 长远（湖南）数字科技有限公司 算法工程师

参与实现医疗领域RAG系统，日均处理50,000+医疗咨询，覆盖7类核心意图。参与混合检索模块开发，采用PubMedBERT+Milvus+ES构建意图导向检索系统，MRR@5达0.87；设计高频问答模块，BM25相似度>0.85且通过安全检查则直接返回缓存答案，缓存命中率45%；实现三重合规校验机制，误诊风险率降至0.28%。100%符合医疗合规要求。

2025-02 ~ 2025-04

参与了文本分类系统的算法开发与优化。参与了从数据清洗、构建基线模型到模型部署的全流程工作，通过对FastText、BERT等模型的对比实验与迭代优化，将文本分类准确率从基线模型的85%提升至94.5%，为业务提供了高效的自动化分类能力。

项目经历

医疗RAG智能问答系统

技术栈：PubMedBERT、milvus、MedLLM-7B、RAGAS、Elasticsearch、redis、python

项目背景：设计并实现面向医疗领域的RAG智能问答系统，日均处理5万+医疗咨询，覆盖症状咨询、药品查询等7类核心意图。严格遵循医疗合规标准，提供安全准确的医疗信息，满足《互联网诊疗监管细则》要求。系统误诊风险率0.28%，MRR@5达0.87，100%符合医疗安全规范。

主要职责:

- 设计混合检索策略：结合BM25关键词检索与向量检索，实现0.4×BM25 + 0.6×向量得分的动态融合机制。
- 实现意图导向检索：按7类意图物理分库（ES索引+Milvus集合），MRR@5提升19.4%至0.87。
- 开发重排序模块：集成权威性权重（指南×1.2 > 文献×1.0 > 科普×0.7）和时效性过滤（剔除>2年内容）。
- 意图识别模块优化：微调PubMedBERT模型，人工客服识别F1提升至93.3%。
- 高频问答模块设计与安全机制：构建安全的高频问答流程、设计医疗安全过滤机制。
- 生成与合规校验：开发医疗专属提示词模板、实现三重合规校验、设计人工客服转接机制，转接准确率95.3%。

项目成果

- MRR@5达0.87（比行业基准高19.4%），响应延迟P95仅780ms，支持5.2万+/日医疗咨询。
- 误诊风险率降至0.28%（行业基准1.52%），三重合规校验机制使合规率98.7%，年预估避免4,200+例误诊。
- 高频问答模块缓存命中率45.3%，减少54.7%的RAG流程调用；意图导向检索使权威内容占比90.2%。
- 100%满足《互联网诊疗监管细则》要求，时效性过滤覆盖率100%，权威内容占比90.2%。

多智能体协作的智能旅行规划平台

技术栈：Vue.js, Node.js, Python, FastAPI, Langchain, Gaode Map API, Unsplash API ,Qwen

项目描述：一个前后端分离的智能旅行规划系统。后端基于 FastAPI 构建多智能体协作网络，前端采用 Vue + Node.js 实现交互式界面。系统通过协调 4 个专用智能体，为用户提供从景点搜索、酒店推荐到行程生成的闭环服务，并集成第三方 API 实现数据可视化。

核心工作:

多智能体架构设计：设计并实现了 4 个专用 Agent（景点搜索、酒店推荐、天气查询、行程规划），通过 主从协作模式 将用户复杂需求拆解为子任务，解决了单一模型在处理多步骤任务时的逻辑混乱问题。

外部工具链集成：为 Agent 绑定 高德地图 API 获取真实 POI 数据与路线信息，集成 Unsplash API 自动匹配景点高清图片，确保了生成内容的实时性与视觉吸引力，避免了模型幻觉。

全栈工程化实现：前端使用 Vue.js + Node.js 构建响应式界面，通过 Axios 与后端 FastAPI 通信；后端采用异步编程处理高并发 Agent 请求，显著提升用户等待体验。

数据标准化处理：定义了统一的 JSON 数据协议，规范了各 Agent 的输出格式，确保前端能准确渲染行程卡片、地图标记及图片画廊，实现了前后端数据的无缝对接。

项目成果:

成功集成高德与 Unsplash 接口，累计测试 50+ 个不同城市旅行场景，无重大 API 调用错误。

设计结构化 JSON 输出协议，前端解析成功率达 100%，避免了传统 LLM 输出格式不稳定导致的页面报错。

通过工具调用替代纯模型生成，解决了大模型在地理位置与实时天气上的幻觉问题，信息准确率达 95%+。

- **数据及预处理**：开发了模块化、可配置的数据预处理框架，包括：深度清洗、文本规范化、关键信息保留
- **确立可靠基线**：首先构建基于TF-IDF特征与随机森林的基线模型，快速验证了数据流程与标签体系的有效性，其85%的准确率为后续优化提供了明确参照。
- **效率优先探索**：为满足潜在的高吞吐、低延迟场景，引入FastText模型进行对比。通过精细调整n-gram特征与损失函数，在保证90%+准确率的同时，将线上单条预测耗时降至3毫秒以内，展现了极佳的性价比。
- **深度模型优化与上线**：为追求极致效果，采用预训练语言模型BERT进行微调，有效缓解过拟合，该模型在独立测试集上达到94.5%的准确率，综合F1值较基线提升12%，成为线上服务的核心模型。
- **模型压缩**：通过模型量化、知识蒸馏等技术，训练TextCNN模型，提升用户体验，Teacher模型测试集准确率为93.64%，Student模型测试集准确率为89.89%和91.25%。

减少80%人工分类，用户满意度提升60%，平台日均浏览量显著提升。

机械设计制造及其自动化 (本科)

为人开朗，性格随和，可以快速融入团队；
对待工作认真负责，积极主动解决问题，并在工作中不断寻求提升，抗压能力强。